中文字符编码标准+Unicode+Code Page

2011 年 10 月 21 日 下午 4:38 ▲ crifan ●已有3026人围观 ■ 我来说几句

中文字符编码标准+Unicode+Code Page

Version: 2011-10-21
Author: crifan

Mail: green-waste (at) 163.com

此文的PDF版本可以去这下载:

中文字符编码标准+Unicode+Code Page

http://bbs.chinaunix.net/thread-3610023-1-1.html

【中文字符编码标准】

1. GB2312, CP936, GBK, GB18030, GB13000

(1) GB2312

1980年,中国制定了GB2312-80,一共收录了 7445 个字符,包括 6763 个汉字和 682 个其它符号。

GB2312-80, 简称为GB2312。

在 Windows 中的代码页 (Code Page) 是 CP936。

(2) GB13000

1993年,国际标准Unicode 1.1版本推出,收录中国大陆、台湾、日本及韩国通用字符集的汉字,总共有20,902个。

中国大陆订定了等同于Unicode 1.1版本的 "GB 13000.1-93" , 简称为GB13000。

GB13000,显然包含的GB2312已有的文字和其他很多为包含的文字,如GB 2312-80推出以后才简化的汉字(如"啰"),部分人名用字(如中国前总理朱镕基的"镕"字),台湾及香港使用的繁体字,日语及朝鲜语汉字等。

(3) GBK

微软,对GB2312-80的扩展,即利用GB 2312-80未使用的编码空间,收录所有的GB 13000.1-93和Unicode 1.1之中的汉字全部字符,制定了GBK编码。

GBK 收录了 21886 个符号,它分为汉字区和图形符号区。汉字区包括 21003 个字符。

GBK 作为对 GB2312 的扩展,在现在的 Windows 系统中仍然使用代码页 CP936 表示,但是同样的 936 的代码页跟一开始的 936 的代码页只支持 GB2312 编码不同,现在的 936代码页支持 GBK 的编码,GBK 同时也向下兼容GB2312 编码。

所以,技术编码上,GBK兼容旧的GB2312,但是编码方式和GB13000不同,不兼容GB13000,但是所包含文字上,算是和GB13000相同。

(4) GB18030

GBK自身并非国家标准,只是曾由国家技术监督局标准化司、电子工业部科技与质量监督司公布为"技术规范指导性文件"。

原始GB13000一直未被业界采用,2000年,国家出了标准GB18030-2000,简称GB18030,技术上兼容GBK而非GB13000,取代了GBK1.0,成了正式的国家标准。

该标准收录了 27484 个汉字,同时还收录了藏文、蒙文、维吾尔文等主要的少数民族文字。 现在的PC平台必须支持 GB18030 ,对嵌入式产品暂不作要求。所以手机、MP3 一般只支 持 GB2312。

GB18030 在 Windows 中的代码页是 CP54936。

这么多汉字编码标准的关系,总结起来就是:

2. 各种中文字符编码标准的关系

(中国大陆的标准) GB 13000.1-93 = (国际标准) Unicode 1.1

(中国大陆标准) GB2312-80

- = 简称GB2312
- = Windows系统中的原先的CP936

(微软制定的) GBK

- = (微软在编码方面)对GB2312的扩展
- = (微软在所包含字符方面上包含了) GB 13000.1-93 + 其他部分汉字+ 台湾和香港的繁体 + 日语 + 朝鲜汉字
- = Unicode 1.1 + 其他部分汉字+ 台湾和香港的繁体 + 日语 + 朝鲜汉字

对于GBK:

≤ 在编码方面:向下兼容GB2312,但是和GB 13000不同

≤ 在内容方面:等价于GB13000

微软中 现在的新的CP936

= GBK

=兼容旧的GB2312

在技术编码方面上,演化顺序为, ASCII -> GB2312 -> GBK -> GB18030。

后者对之前的,都是支持之前的编码,即向下兼容,即同一个字符,在这些编码中,都是同样的值,后面的标准,支持更多的字符。

区分中文编码的方法是高字节的最高位不为 0。

按照程序员的称呼, GB2312、GBK 到 GB18030 都属于双字节字符集 (DBCS)。

编码标准	别名	标准所属	包含字符
ASCII		国际通用	
GB2312	微软Windows中以前	中国大陆	6763 个汉字和 682 个其它符
	的CP936		号
Unicode 1.1		国际通用	20,902个字符
GB13000		中国大陆	20,902个字符
GBK	微软Windows中现在	微软	21886 个符号
	的CP936		
GB18030	微软Windows中的	中国大陆	27484 个汉字+其他少数民族
	CP54936		字符

图表 1 中文字符相关编码标准

[Unicode]

世界上有很多个国家(和地区),每个国家都有自己对应的字符编码。

如果把各种文字编码形容为各地的方言,那么Unicode就是世界各国合作开发的一种语言。

在这种语言环境下,不会再有语言的编码冲突,在同屏下,可以显示任何语言的内容,这就是Unicode的最大好处。

那么Unicode是如何编码的呢?其实非常简单。

就是将世界上所有的文字用 2 个字节统一进行编码。可能你会问, 2 个字节最多能够表示65536个编码,够用吗?

韩国和日本的大部分汉字都是从中国传播过去的,字型是完全一样的。

比如:"文"字,GBK和SJIS中都是同一个汉字,只是编码不同而已。

那样,像这样统一编码,2个字节就已经足够容纳世界上所有的语言的大部分文字了。

Unicode的学名是"Universal Multiple-Octet Coded Character Set",简称为UCS。

现在用的是UCS-2,即2个字节编码,而UCS-4是为了防止将来2个字节不够用才开发的。UCS-2也称为基本多文种平面。

UCS-2转换到UCS-4只是简单的在前面加 2 个字节0。UCS-4则主要用于保存辅助平面,例如

Unicode 4.0中的第二辅助平面:

20000-20FFF - 21000-21FFF - 22000-22FFF - 23000-23FFF - 24000-24FFF - 25000-25FFF - 26000-26FFF - 27000-27FFF - 28000-28FFF - 29000-29FFF - 2A000-2AFFF - 2F000-2FFFF 总共增加了16个辅助平面,由原先的65536个编码扩展至将近100万编码。